

## Formulaire examen intra MAT4681

- L'union de deux ensembles  $A$  et  $B$ , noté  $A \cup B$ , contient les éléments de  $A$  et les éléments de  $B$

$$A \cup B = \{x : x \in A \text{ ou } x \in B\}$$

- L'intersection de deux ensembles  $A$  et  $B$ , notée  $A \cap B$ , est l'ensemble des éléments de  $A$  qui sont aussi éléments de  $B$

$$A \cap B = \{x : x \in A \text{ et } x \in B\}$$

- La permutation fait référence aux différentes façons d'organiser un ensemble d'objets dans un ordre séquentiel.
- La combinaison fait référence à plusieurs manières de choisir des éléments dans un grand ensemble d'objets, de sorte que leur ordre n'a pas d'importance.
- Une probabilité est une fonction  $\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$  telle que
  - $\mathbb{P}(\emptyset) = 0$  et  $\mathbb{P}(\Omega) = 1$
  - si  $A \cap B = \emptyset$ ,  $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B)$
 où  $\mathcal{F}$  est l'ensemble des parties de  $\Omega$ .

- $A_1, \dots, A_k$  forme une partition de  $\Omega$  si
  - $A_1 \cup \dots \cup A_k = \Omega$
  - $\forall i, j, A_i \cap A_j = \emptyset$

- Soient deux événements  $A$  et  $B$  (dans  $\mathcal{F}$ ) tels que  $\mathbb{P}(B) \neq 0$ , on note

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

- Deux événements  $A$  et  $B$  (dans  $\mathcal{F}$ ) sont indépendants, noté  $A \perp B$ , si

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \times \mathbb{P}(B)$$

- L'exponentielle est l'unique fonction  $f$  dérivable telle que  $f(0) = 1$  et  $f(x) = f'(x) \forall x \in \mathbb{R}$ ,  $f(x) = \exp[x] = e^x$ . Le logarithme est la fonction inverse de l'exponentielle,

$$\log(x) = \int_1^x \frac{dt}{t} \text{ pour } x \in \mathbb{R}_+$$

et  $\log[e^x] = x$ , pour  $x \in \mathbb{R}$ .

- $\log(xy) = \log(x) + \log(y)$   
 $\log(x^y) = y \log(x)$   
 $\exp(x+y) = \exp(x) \exp(y)$

- La fonction Gamma est définie par

$$\Gamma : z \mapsto \int_0^{+\infty} t^{z-1} e^{-t} dt \text{ pour } z \in \mathbb{R}_+$$

Pour  $z \in \mathbb{N}$ ,  $\Gamma(z+1) = z!$ ,  $\Gamma(1) = 1$  et  $\Gamma(1/2) = \sqrt{\pi}$ .

- Soit  $f$  définie sur  $[a, b]$ , et  $F$  telle que  $F' = f$ , alors

$$\int_a^b f(x) dx = F(b) - F(a)$$

- Pour une variable aléatoire  $X$  discrète, la fonction de masse est  $f(a) = \mathbb{P}(X = a)$  et la fonction de répartition est  $F(a) = \mathbb{P}(X \leq a)$ .

- $X$  et  $Y$  sont indépendantes ( $X \perp Y$ ) si et seulement si

$$\begin{cases} f(x, y) = f_X(x) \cdot f_Y(y), \forall x, y \\ F(x, y) = F_X(x) \cdot F_Y(y), \forall x, y \end{cases}$$

- Loi de Bernoulli  $\mathcal{B}(p)$ ,  $x \in \{0, 1\}$

$$f(x) = \mathbb{P}(X = x) = \begin{cases} p & \text{si } x = 1, \\ 1 - p & \text{si } x = 0, \\ 0 & \text{sinon.} \end{cases}$$

où  $p \in [0, 1]$ , soit

$$\mathbb{P}(X = x) = p^x (1 - p)^{1-x}, x \in \{0, 1\}$$

- Loi binomiale  $\mathcal{B}(n, p)$ ,  $x \in \{0, 1, \dots, n\}$

$$f(x) = \binom{n}{x} p^x (1 - p)^{n-x}, x \in \{0, 1, \dots, n\}$$

où  $p \in [0, 1]$ , et  $n \in \mathbb{N}_*$ .

- Loi de Poisson  $\mathcal{P}(\lambda)$ ,  $x \in \{0, 1, \dots\} = \mathbb{N}$

$$f(x) = \mathbb{P}(X = x) = e^{-\lambda} \frac{\lambda^x}{x!}, x \in \mathbb{N},$$

où  $\lambda \in \mathbb{R}_+$ .

- Loi Géométrique  $\mathcal{G}(p)$  sur  $\mathbb{N}_*$

$$f(x) = \mathbb{P}(X = x) = p(1 - p)^{x-1} \text{ pour } x = 1, 2, \dots$$

où  $p \in [0, 1]$ , avec  $F(x) = \mathbb{P}(X \leq x) = 1 - p^x$ .

- Loi de Zipf  $\mathcal{Z}(\alpha)$  ou  $\mathcal{Z}(n, \alpha)$

Définie pour  $x \in \{1, 2, \dots, n\}$  par  $f(x) \propto x^{-\alpha}$  où  $\alpha > 0$ . Plus précisément, si on

note  $H_{n,s} = \sum_{k=1}^n \frac{1}{k^s}$  le  $n$ -ème nombre harmonique généralisé,

$$f(x) = \frac{x^{-\alpha}}{H_{n,\alpha}}, x \in \{1, 2, \dots, n\}$$

- Loi de Benford

Si  $X$  prend les valeurs  $\{1, 2, \dots, 9\}$ , et

$$f(x) = \log_{10}(x+1) - \log_{10}(x) = \log_{10}\left(1 + \frac{1}{x}\right)$$

- Si  $X$  prend les valeurs  $\{x_1, x_2, \dots, x_k\}$ , avec la fonction de masse  $f$ , son espérance est

$$\mathbb{E}[X] = \sum_{i=1}^k f(x_i) \cdot x_i$$

- La variance de  $X$  est définie par

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$$

aussi, si  $X$  prend les valeurs  $\{x_1, x_2, \dots, x_k\}$ , avec la fonction de masse  $f$ , si  $\mu = \mathbb{E}[X]$ , sa variance est définie par

$$\text{Var}[X] = \sum_{i=1}^k f(x_i) \cdot (x_i - \mu)^2$$

- L'écart-type de  $X$  est défini par

$$\sigma(X) = \sqrt{\text{Var}(X)}$$

- Si  $X$  est une variable aléatoire continue, sa fonction de répartition est  $F(a) = \mathbb{P}(X \leq a)$  et la densité est

$$f(a) = \left. \frac{dF(x)}{dx} \right|_{x=a} = F'(a)$$

- $X$  suit une loi uniforme sur  $[0, 1]$ , noté  $X \sim \mathcal{U}([0, 1])$  si  $f(x) = \mathbf{1}_{[0,1]}(x)$ ,  $x \in \mathbb{R}$ . La fonction de répartition est

$$F(x) = \mathbb{P}[X \leq x] = \begin{cases} 0 & \text{si } x \leq 0 \\ x & \text{si } x \in [0, 1] \\ 1 & \text{si } x \geq 1 \end{cases}$$

- $X$  suit une loi uniforme sur  $[a, b]$  si  $f(x) = \frac{1}{b-a} \mathbf{1}_{[a,b]}(x)$ .

Si  $X$  suit une loi uniforme sur  $[0, 1]$ , pour tout  $a, b$ ,  $a > 0$ ,  $Y = aX + b$  suit une loi uniforme sur  $[b, b+a]$ .

- Loi exponentielle de paramètre  $\lambda$  (sur  $\mathbb{R}_+$ )  
Pour  $\lambda > 0$ ,  $X \sim \mathcal{E}(\lambda)$  si

$$f(x) = \lambda e^{-\lambda x} \mathbf{1}_{\mathbb{R}_+}(x)$$

ou

$$F(x) = (1 - e^{-\lambda x}) \mathbf{1}_{\mathbb{R}_+}(x)$$

- $X$  suit une loi de Pareto si

$$\mathbb{P}[X \leq x] = 1 - x^{-\alpha}, \text{ pour } x \geq 1$$

pour  $\alpha \in \mathbb{R}_+$ .

Si  $X \sim \mathcal{P}(\alpha)$ ,  $Y = \log X$  suit une loi exponentielle  $\mathcal{E}(\alpha)$ .

- Loi normale, centrée réduite (sur  $\mathbb{R}$ )  
 $X \sim \mathcal{N}(0, 1)$  admet pour densité, pour  $x \in \mathbb{R}$ ,

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$$

- Loi normale (sur  $\mathbb{R}$ )  
 $X \sim \mathcal{N}(\mu, \sigma^2)$  admet pour densité

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

- Si  $X \sim \mathcal{N}(\mu, \sigma^2)$ ,

$$Z = \frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1)$$

- Si  $X$  a pour densité  $f$ ,

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x f(x) dx$$

(si l'intégrale est convergente).

- Si  $X$  a pour densité  $f$ ,

$$\text{Var}[X] = \int_{-\infty}^{+\infty} (x - \mathbb{E}[X])^2 f(x) dx$$

(si l'intégrale est convergente).

- Si  $X$  a pour moyenne  $\mu$  et pour variance  $\sigma^2$ ,

$$Z = \frac{X - \mu}{\sigma}$$

est la version centrée et réduite de  $X$ .

$Z$  est centrée car  $\mathbb{E}[Z] = 0$  et réduite car  $\text{Var}[Z] = 1$ .

- Si  $X \sim \mathcal{N}(\mu, \sigma^2)$ ,  $\mathbb{E}[X] = \mu$  et  $\text{Var}[X] = \sigma^2$

- Loi des grands nombres

Soient  $X_1, X_2, \dots$  des variables i.i.d. de même moyenne  $\mu$  et de même variance  $\sigma^2$ . Soit

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = \frac{X_1 + \dots + X_n}{n}$$

alors pour tout  $\varepsilon$  (aussi petit que possible),

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mu| < \varepsilon) = 1$$

- Théorème Central Limite

Soient  $X_1, X_2, \dots$  des variables i.i.d. de même moyenne  $\mu$  et de même variance  $\sigma^2$ . Soit

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = \frac{X_1 + \dots + X_n}{n}$$

alors

$$\sqrt{n} \cdot \frac{\bar{X}_n - \mu}{\sigma} \approx \mathcal{N}(0, 1).$$

- $X$  et  $Y$  sont indépendants (noté  $X \perp\!\!\!\perp Y$ ) si et seulement si

$$\begin{cases} F(x, y) &= F_X(x) \cdot F_Y(y), \forall x, y \in \mathbb{R} \\ f(x, y) &= f_X(x) \cdot f_Y(y), \forall x, y \in \mathbb{R} \end{cases}$$

- On appelle covariance d'un couple de variable aléatoire

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$$

qui s'écrit aussi

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$$

(à condition que  $\mathbb{E}[X^2] < \infty$  et  $\mathbb{E}[Y^2] < \infty$ ).

- On appelle corrélation d'un couple de variable aléatoire

$$\text{Cor}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \cdot \text{Var}(Y)}}$$

(à condition que  $\mathbb{E}[X^2] < \infty$  et  $\mathbb{E}[Y^2] < \infty$ ).

- Pour un échantillon  $\{y_1, \dots, y_n\}$ , la moyenne est  $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$

La moyenne est la version empirique de l'espérance d'une variable aléatoire,

$$\mathbb{E}(X) = \sum_x x \mathbb{P}[X = x] \text{ si } \sum_x |x| \mathbb{P}[X = x] < \infty$$

$$\mathbb{E}(X) = \int x f(x) dx \text{ si } \int |x| f(x) dx < \infty$$

- La moyenne tronquée de niveau  $\alpha \in [0, 1]$  est

$$\frac{1}{n - 2k} \sum_{i=k+1}^{n-k} x_i \text{ où } k = \lfloor \alpha n \rfloor$$

- La Moyenne olympique (Olympic average) est

$$\frac{x_2 + x_3 + x_4 + x_5 + x_6 + x_7 + x_8 + x_9}{8}$$

- La moyenne de Windsor (Winsorized average) est

$$\frac{\overbrace{x_2 + x_2} + x_3 + x_4 + x_5 + x_6 + x_7 + x_8 + \overbrace{x_9 + x_9}}{10}$$

- Pour une fonction de répartition  $F$ ,

$$Q(p) = \inf \{x \in \mathbb{R} : p \leq F(x)\}$$

est la fonction quantile. Le quantile est la seule fonction telle que

$$Q(p) \leq x \text{ si et seulement si } p \leq F(x)$$

Si  $F$  est continue et strictement croissante  $Q(p) = F^{-1}(p)$ .

$Q$  est l'inverse à gauche :

$$Q(F(X)) = X$$

- Quantile empirique (1)

Notons  $\{x_{(i)}\}$  une version ordonnée de  $\{x_i\}$ ,  $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$ . Le quantile empirique de niveau  $p \in (0, 1)$  est

$$\hat{q}_p = (1 - f)x_{(k)} + fx_{(k+1)}$$

où  $k = \lceil np \rceil$  et  $f = n\alpha - \lfloor np \rfloor$ .

- Quantile empirique (2)  
Étant donné  $\{x_i\}$ , si  $\hat{F}$  est la fonction de répartition empirique associée, on peut poser

$$\tilde{q}_p = \hat{F}^{-1}(p) = x_{(k)} \text{ où } k = \lceil np \rceil$$

- Notons  $\{x_{(i)}\}$  une version ordonnée de  $\{x_i\}$ ,  $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$ . On appelle médiane  $Q(1/2)$ , et sa version empirique est

$$md(x) = \begin{cases} x_{((n+1)/2)} & \text{si } n \text{ impair} \\ \frac{1}{2}(x_{(n/2)} + x_{(n/2+1)}) & \text{si } n \text{ pair} \end{cases}$$

- Variance empirique (version 1)  
Étant donné un échantillon  $x_1, \dots, x_n$ , on appelle variance empirique

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

- Variance empirique (version 2)  
Étant donné un échantillon  $x_1, \dots, x_n$ , on appelle variance empirique

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

- Étant donné un échantillon apparié  $(x_1, y_1), \dots, (x_n, y_n)$ , la covariance empirique est

$$\text{cov} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

- Étant donné un échantillon  $x_1, \dots, x_n$ , on appelle écart-type empirique

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

- L'intervalle interquartile (IQR) est

$$\text{IQR} = Q(3/4) - Q(1/4)$$

- On appelle coefficient de variation le ratio

$$CV(X) = \frac{\sqrt{\text{Var}[X]}}{\mathbb{E}[X]} \text{ et } cv(x) = \frac{s}{\bar{x}}.$$

- Étant donné un échantillon  $x = \{x_1, x_2, \dots, x_n\}$ , la fonction de répartition empirique est  $\hat{F}$  où

$$\hat{F}(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}(x_i \leq x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{[x_i, \infty)}(x)$$

- Étant donné un échantillon  $x = \{x_1, x_2, \dots, x_n\}$  associé à une loi continue, soient

$$\begin{cases} a_0 < \min\{x_1, x_2, \dots, x_n\}, & a_k > \max\{x_1, x_2, \dots, x_n\} \\ a_{j+1} = a_j + h = a_0 + (j+1)h \end{cases}$$

est un estimateur de la densité  $f$  est l'histogramme

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n \mathbf{1}_{[a_j, a_{j+1})}(x_i) \text{ où } j \text{ tel que } x \in [a_j, a_{j+1})$$

- Un noyau  $k$  est une fonction de densité centrée sur 0, i.e.

$$\int_{-\infty}^{+\infty} xk(x)dx = 0$$

- Étant donné un échantillon  $x = \{x_1, x_2, \dots, x_n\}$ , un estimateur de la densité  $f$  est  $\hat{f}_h$ , pour  $h > 0$ ,

$$\hat{f}_h(x) = \frac{1}{n} \sum_{i=1}^n k_h(x - x_i), \text{ où } k_h(\cdot) = \frac{1}{h} k\left(\frac{\cdot}{h}\right)$$

- $X$  suit une loi du chi-deux, à  $\nu$  degrés de liberté, noté  $X \sim \chi^2(\nu)$ , où  $\nu \in \mathbb{N}^*$  si  $X$  a pour densité

$$x \mapsto \frac{(1/2)^{\nu/2}}{\Gamma(\nu/2)} x^{\nu/2-1} e^{-x/2}, \text{ où } x \in [0; +\infty),$$

- Si  $X_1, \dots, X_\nu \sim \mathcal{N}(0, 1)$  sont des variables indépendantes

$$Y = \sum_{i=1}^{\nu} X_i^2 \sim \chi^2(\nu)$$

où  $\nu \in \mathbb{N}_*$

- Soit  $X_1, \dots, X_n$  des variables  $\mathcal{N}(\mu, \sigma^2)$  indépendantes, alors

$$S_n^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2$$

suit une loi  $\chi^2(n-1)$ .

- $X$  suit une loi de Student,  $St(\nu)$ , à  $\nu$  degrés de liberté, si  $X$  a pour densité

$$f(t) = \frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\nu\pi} \Gamma(\frac{\nu}{2})} \left(1 + \frac{t^2}{\nu}\right)^{-\left(\frac{\nu+1}{2}\right)}, \text{ sur } \mathbb{R}$$

where  $\Gamma$  denotes the Gamma function ( $\Gamma(n+1) = n!$ ).

- Si  $X \sim \mathcal{N}(0, 1)$  et  $Y \sim \chi^2(\nu)$  sont indépendantes, alors

$$T = \frac{X}{\sqrt{Y/\nu}} \sim St(\nu).$$

- Soient  $X_1, \dots, X_n$  des variables indépendantes  $\mathcal{N}(\mu, \sigma^2)$ . Posons

$$\bar{X}_n = \frac{X_1 + \dots + X_n}{n} \text{ et } S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$

alors

$$\frac{(n-1)S_n^2}{\sigma^2}$$

suit une loi  $\chi^2(n-1)$  et

$$T = \sqrt{n} \frac{\bar{X}_n - \mu}{S_n} \sim St(n-1).$$

Si  $X \sim \mathcal{N}(0, 1)$ , on a les probabilités suivantes

$$\left\{ \begin{array}{ll} \mathbb{P}[X \leq -3] \approx 0.1350\% & \mathbb{P}[X \leq -2.326348] \approx 1\% \\ \mathbb{P}[X \leq -2] \approx 2.2750\% & \mathbb{P}[X \leq -1.959964] \approx 2.75\% \\ \mathbb{P}[X \leq -1] \approx 15.865\% & \mathbb{P}[X \leq -1.644854] \approx 5\% \\ \mathbb{P}[X \leq 0] = 50.0000\% & \mathbb{P}[X \leq -1.281552] \approx 10\% \\ \mathbb{P}[X \leq 1] \approx 84.1345\% & \mathbb{P}[X \leq 0.6744898] \approx 75\% \\ \mathbb{P}[X \leq 2] \approx 97.7250\% & \mathbb{P}[X \leq 0.8416212] \approx 80\% \\ \mathbb{P}[X \leq 3] \approx 99.8650\% & \mathbb{P}[X \leq 1.281552] \approx 90\% \\ \mathbb{P}[X \leq 4] \approx 99.9968\% & \mathbb{P}[X \leq 1.644854] \approx 95\% \end{array} \right.$$